Національний університет «Львівська політехніка»
Кафедра систем штучного інтелекту

ЛАБОРАТОРНА РОБОТА № 6

Конвеєр інтелектуального аналізу даних та інтерпретація моделі

Методичні вказівки до виконання

Інтелектуальний аналіз та візуалізація даних

4 години · 4 бали · ноутбук «ЛР6_завдання_студенту.ipynb»

Львів · 2026

1. Мета і постановка задачі

1.1. Що ви робите

Ви — аналітик інтернет-провайдера. Відділ маркетингу просить модель, яка **в момент звернення клієнта** оцінює ризик того, що він розірве договір протягом кварталу. Модель потрібна не заради числа: за її підказкою відділ утримання телефонуватиме людям і пропонуватиме знижку.

Тому від вас хочуть дві речі, і друга не менш важлива за першу:

- **чесну оцінку якості** — число, якому можна вірити;
- **пояснення** — чому модель вважає конкретного клієнта ризиковим.

Вам видано вивантаження з CRM. Воно зроблене не для аналізу, а для звітності, тому містить усе підряд — зокрема й те, чого в момент прогнозу ще не існує.

> Попередження, яке варто прочитати двічі: перший результат, який ви отримаєте, буде прекрасним. Робота полягає в тому, щоб з'ясувати, чому йому не можна вірити, і скільки залишиться після того, як ви приберете все зайве.

1.2. Чого ви маєте навчитись

№	Уміння	Де перевіряється
1	Ухвалювати рішення про тип задачі, метрику і схему перевірки **до** роботи з даними	розділ 1 ноутбука
2	Знаходити й усувати всі чотири типи витоку, а не лише очевидний	розділи 5–6
3	Збирати конвеєр так, щоб препроцесинговий витік став неможливим	розділ 3
4	Обґрунтовувати вибір методу виміряними числами, а не загальними словами	розділ 7
5	Конструювати ознаки зі знання предметної області	розділи 8, 10
6	Читати пояснення моделі й **упізнавати випадки, де вони вводять в оману**	розділи 9–12

1.3. Що здаєте

Заповнений ноутбук `ЛР6_завдання_студенту.ipynb`, який виконується **згори вниз без помилок на чистому ядрі**, і файл `lr6_результат_NN.json`, що створюється останньою коміркою.

> Перевірка починається з Kernel → Restart & Run All. Ноутбук, який не проходить цю перевірку, повертається на доопрацювання зі штрафом 0,5 бала незалежно від змісту.

1.4. Ваш варіант

Варіант визначається номером у списку групи: `варіант = (номер − 1) mod 30 + 1`. Файл даних — `дані/lr6_варіант_NN.csv`.

> Набори різні не лише числами. У кожному варіанті роль кожної пастки грає ІНШИЙ стовпець. Відповідь, переписана в сусіда, не збігається з вашими даними — і це видно з першого погляду.

2. Опис набору даних

Файл містить 1200 рядків — по одному на клієнта — і 25–26 стовпців залежно від варіанта. Цільова змінна — відтік (1 — розірвав договір, 0 — лишився). Частка відтоку в різних варіантах від 0,15 до 0,30.

2.1. Ознаки, відомі в момент звернення

Стовпець	Що означає
id_клієнта	технічний ідентифікатор
вік	вік клієнта, роки
стать	записана неохайно: ч, Ч, чол, ж, Ж, жін
місто, філія	де обслуговується клієнт
тариф, тип_підключення	базовий, оптимальний, максимальний, бізнес; оптика / ADSL / радіо
спосіб_оплати, автоплатіж	картка / термінал / каса; чи налаштовано автосписання
кількість_послуг	інтернет, ТБ, телефон — скільки з них підключено
місяців_обслуговування	стаж клієнта
дата_підключення	коли підключився
швидкість_тарифу_Мбіт	швидкість за договором
щомісячний_платіж	грн на місяць
знижка_відсоток	діюча знижка: 0, 10 або 20 %
трафік_ГБ	спожитий трафік за квартал
кількість_звернень_у_підтримку	скільки разів звертався
аварій_на_ділянці_за_квартал	аварій на його ділянці мережі
середній_час_відповіді_хв	середній час відповіді підтримки

2.2. Стовпці, щодо яких треба поставити питання

Решта стовпців наведена без пояснень **навмисно**. Вирішити, що з ними робити, — частина завдання. Залежно від варіанта серед них трапляються:

Стовпець	Коли з'являється в житті клієнта
дата_розірвання	—
сума_повернення_депозиту	—
код_причини_закриття	—
оцінка_ризику_менеджером	—
кількість_дзвінків_утримання	—
трафік_МБ або річний_платіж	—
код_тарифного_плану або номер_договору_серія	—
індекс_лояльності_CRM або скоринг_партнера	—

> Другий стовпець таблиці заповнюєте ви. Це і є головна робота першої частини: для кожного поля з'ясувати, в який момент воно з'являється — і чи існує воно в ту мить, коли треба ухвалити рішення.

3. Теоретичні відомості, потрібні для виконання

Усе нижче докладно викладено в теоретичному конспекті лекції 7; тут — стисло, із посиланнями на його розділи.

3.1. Метрика

НОВИЙ ТЕРМІН · **AUC** Імовірність того, що для випадково взятої пари «один клієнт, який пішов, і один, який лишився» модель дала першому вищу оцінку ризику. Не залежить від порога.

0,5 — модель не відрізняє класи; 0,8–0,9 — добра модель; 0,95 і вище на реальних даних — майже завжди ознака витоку. Конспект, розділ 4.4.

Точність (accuracy) у цій задачі непридатна як головна метрика. Відтік становить 15–30 %, тож модель «ніхто не піде» має точність 70–85 % при нульовій користі. Перше, що варто обчислити, — саме це число: воно задає планку, нижче якої говорити нема про що.

3.2. Схема перевірки

Стратифікована k-кратна крос-валідація з повторами (конспект, розділ 5.3). У ноутбуці задано схему 5 згорток × 4 повтори: кожне число — середнє з двадцяти навчань моделі.

Звітуйте не одне число, а середнє і розкид: «AUC 0,822 ± 0,038». Різниця двох моделей у 0,004 при розкиді 0,038 нічого не означає — для порівняння потрібне парне зіставлення (розділ 11.4 конспекту).

3.3. Чотири типи витоку

Тип	У чому полягає	Чим усувається
цільовий	ознака є наслідком цілі: дата розірвання, сума повернення	чек-ліст: чи існує значення в момент прогнозу
препроцесинговий	параметри обробки оцінені на всій вибірці	конвеєр
часовий	навчання на майбутньому, перевірка на минулому	часова схема перевірки
груповий	один об'єкт і в навчанні, і в перевірці	групова схема перевірки

Поширене уявлення «ми використали Pipeline, отже витоку немає» хибне. Конвеєр усуває рівно ОДИН тип із чотирьох. Решту ловить не код, а питання про те, звідки взялися дані.

3.4. Артефакт збору даних

НОВИЙ ТЕРМІН · **Артефакт збору даних** Систематична відмінність між групами спостережень, спричинена не предметом дослідження, а обставинами запису: різні періоди, різні джерела, різні люди, що заповнювали документи.

Якщо два класи зібрані по-різному, модель вивчає спосіб запису, а не предмет. Жодна окрема колонка при цьому не є витоком — витоком є вся таблиця. Конспект, розділ 9.3.

Обчислювана перевірка: спробувати передбачити тими самими ознаками не ціль, а **джерело** — філію або період підключення. Якщо AUC помітно вища за 0,5, у даних закодовано, з якої групи клієнт.

3.5. Три інструменти пояснення

НОВИЙ ТЕРМІН · **Вбудована важливість (impurity-based)** Наскільки кожна ознака зменшувала неоднорідність при розбиттях дерева. Рахується на навчальних даних і **систематично переоцінює** ознаки з великою кількістю різних значень.

НОВИЙ ТЕРМІН · **Перестановочна важливість (permutation importance)** Беремо навчену модель, перемішуємо значення однієї ознаки в перевірковій частині й дивимось, наскільки впала якість. Відповідає на питання «наскільки гірше стане БЕЗ цієї ознаки».

Рахувати обов'язково на перевірковій частині: на навчальній вона показує те саме перенавчання, що й вбудована.

НОВИЙ ТЕРМІН · **Графік часткової залежності (PDP)** Підставляємо всім об'єктам одне й те саме значення ознаки, усереднюємо прогноз, повторюємо для сітки значень. Показує форму впливу: монотонна вона чи ні.

ICE — те саме, але без усереднення: по кривій на кожного клієнта.

НОВИЙ ТЕРМІН · **Значення Шеплі (SHAP)** Розклад прогнозу для ОДНОГО об'єкта на внески окремих ознак так, щоб сума внесків плюс базовий рівень дорівнювала прогнозу. Ідея з теорії кооперативних ігор.

Відповідає на питання «як модель скористалась цією ознакою», а НЕ «що буде, якщо ознаку змінити».

4. Хід роботи

Робота ділиться на дві частини по дві години. Перша закінчується чесним числом, друга — поясненням, якому можна вірити.

Етап	Розділ ноутбука	Що має вийти	Хв
підготовка	0	варіант визначено, пакети встановлено	5
рішення до даних	1	тип задачі, метрика, схема — з обґрунтуванням	10
знайомство з даними	2	три проблеми даних названо	15
матриця ознак і конвеєр	3	`to_number`, `build_X`, `make_pipe` працюють	25
перший результат	4	AUC близько 0,99 і здивування	5
пошук витоку	5	детектор написано, два види витоку усунуто	30
артефакт збору	6	драбина з чотирьох чисел, чесний AUC	20
вибір методу	7	чотири моделі, парне порівняння	15
конструювання ознак	8	три нові ознаки, виміряний приріст	15
важливість ознак	9	дві хибні інтерпретації знайдено	25
PDP, ICE, взаємодія	10	ще дві хибні інтерпретації	25
значення Шеплі	11	пояснення для одного клієнта	20
зведення і звіт	12–15	таблиця помилок, lift, відповіді	20

4.1. Частина 1: від вивантаження до чесного числа

Крок 1. Три рішення до того, як торкнутись даних

Заповніть `TYPE_OF_TASK`, `METRIC`, `CV_SCHEME` і обґрунтуйте кожне одним реченням. Це не формальність: метрика, обрана після того, як побачив результати, — це метрика, яка показала більше.

Крок 2. Знайомство з даними

Знайдіть три проблеми, кожна з яких тихо зламає модель:

- числова колонка, частина значень у якій записана **текстом**;
- колонка, у якій Excel перетворив число на **дату**;
- колонка, пропуски в якій **не випадкові** — їхня наявність сама щось означає.

> Для третьої колонки потрібне не лише ім'я, а й ЗМІСТ пропуску: що саме означає його наявність. Відповідь «там немає даних» не зараховується — немає даних у кожному пропуску.

Крок 3. Матриця ознак і конвеєр

Допишіть `to_number`. Головна пастка: функція не повинна перетворювати дату на число. Клітинка, у якій Excel зробив із числа 11 дату 1900-01-11, містить **брак**, а не дані; правильна реакція — `NaN`.

Далі `build_X`: для кожного стовпця рішення «число / категорія / викинути». Дата підключення має стати числом, інакше модель її не прийме.

Нарешті `make_pipe`: колонковий перетворювач плюс модель, усе в одному об'єкті.

```
ColumnTransformer([
```

```
    ('num', Pipeline([SimpleImputer(strategy='median'), StandardScaler()]), num),
    ('cat', Pipeline([SimpleImputer(strategy='most_frequent'),
                      OneHotEncoder(handle_unknown='ignore')]), cat),
])
```

`handle_unknown='ignore'` — не дрібниця. Без нього модель упаде в ту мить, коли в перевірковій згортці трапиться рівень категорії, якого не було в навчальній. На код_тарифного_плану з 40 рівнями це станеться майже напевно.

Крок 4. Перший результат

Запустіть модель на всьому, що є. Подивіться на число і на таблицю орієнтирів AUC. Запишіть у `FIRST_REACTION`, яка з двох причин високої AUC, найімовірніше, спрацювала.

Крок 5. Пошук витоку

Спершу **автоматичний детектор**: для кожного стовпця перевірити, чи сам факт його заповненості передбачає клас. Поріг `min_group` обов'язковий — без нього детектор спрацьовує на колонках, заповнених у двох клієнтів.

Детектор знайде стовпці з показником близько 1,0. Випишіть їх у `TARGET_LEAK`, для кожного поясніть **одним реченням**, чому його не існує в момент прогнозу, і перерахуйте модель.

Після цього кроку число майже не впаде. Це не помилка і не привід зупинятись — це головний сюжетний поворот роботи. Детектор знаходить колонки, ФОРМАЛЬНО пов'язані з ціллю. Лишилось те, що формально бездоганне.

Далі перегляньте решту стовпців **очима** і поставте кожному питання:

Чи міг я знати це значення в ту мить, коли треба ухвалити рішення?

Момент прогнозу: клієнт щойно зателефонував, договір ЧИННИЙ, рішення про знижку ухвалюється ЗАРАЗ.

Серед стовпців є поле, яке заповнює людина, що **вже бачила поведінку клієнта**. Формально воно не є наслідком відтоку, заповнене в усіх клієнтів, і жоден детектор його не позначить. Знайдіть його, занесіть у `HUMAN_LEAK` і поясніть у `HUMAN_LEAK_WHY`, чому детектор його не спіймав.

Крок 6. Артефакт збору

Порахуйте частку відтоку за філіями і за кварталами дати підключення. Шукайте **сходинку**, а не плавну зміну: плавна зміна була б сезонністю, сходинка означає зміну правила обліку.

Потім проведіть вирішальну перевірку: візьміть ті самі чесні ознаки і спробуйте передбачити ними не відтік, а джерело. Якщо AUC помітно вища за 0,5 — класи не порівнянні.

Завдання 6.4 просить **рішення**: викидати підозрюваний стовпець чи ні. Приймаються обидві відповіді; оцінюється аргумент.

Рішення	Аргумент, який його виправдовує
викинути	модель має працювати в будь-якій філії; зараз вона частково вгадує філію, а не відтік
залишити	філія несе і справжній сигнал — інший склад абонентів, інша щільність забудови
залишити, але звітувати окремо	дати два числа і сказати замовникові, за яких умов модель перенесеться на інші філії

4.2. Частина 2: від числа до пояснення

Крок 9. Дві важливості

Порахуйте вбудовану важливість і перестановочну. Виведіть їх **поруч** в одній таблиці, відсортованій за вбудованою.

> Після одиничного кодування одна категоріальна ознака перетворюється на кілька стовпців. Щоб порівнювати з вихідними ознаками, важливості дамі-стовпців однієї ознаки треба підсумувати — інакше категорія з 40 рівнями виглядатиме неважливою просто тому, що її внесок розмазано на 40 частин.

Перша хибна інтерпретація. Знайдіть ознаку, яка входить у топ-5 за вбудованою важливістю і має перестановочну важливість близько нуля. Така ознака є в кожному варіанті.

Друга хибна інтерпретація. Знайдіть дві ознаки, що вимірюють те саме в різних одиницях (кореляція понад 0,99). Подивіться на їхню перестановочну важливість, потім приберіть одну, навчіть модель заново — і подивіться на важливість тієї, що лишилась.

Крок 10. PDP, ICE і взаємодія

Побудуйте PDP для трьох найважливіших числових ознак. Знайдіть серед них ту, у якої крива **немонотонна**: ризик спадає, а потім знову зростає.

> PDP на ознаці з пропусками дає порожню сітку. Будуйте на підвибірці, де ознака заповнена, і скажіть про це у звіті.

Завдання 10.2б замикає цикл: прочитайте з графіка, при якому значенні ризик мінімальний, побудуйте ознаку «квадрат відхилення від цього значення» і виміряйте, що вона дала **логістичній регресії**. Лісу вона не дасть нічого — він цю форму і так бачив.

Третя хибна інтерпретація. Побудуйте PDP для `знижка_відсоток` по всій вибірці — він буде майже плаский. Потім ICE, потім PDP окремо для клієнтів зі стажем до 24 місяців і понад 24. Звірте з емпіричною таблицею по сирих даних.

> PDP відповідає на питання «як змінюється СЕРЕДНІЙ прогноз». Якщо ефект різноспрямований, середнє близьке до нуля при сильних ефектах у кожній групі.

Крок 11. Значення Шеплі

Порахуйте значення Шеплі, побудуйте зведений графік (`beeswarm`), поясніть прогноз для найризикованішого клієнта **мовою, якою це можна прочитати менеджерові** — без назв стовпців і без слова «модель».

Четверта хибна інтерпретація. Наведіть із свого набору ознаку з великим внеском, втручання в яку нічого не дасть, і поясніть різницю між «модель цим користується» і «це причина».

Вид ознаки	Приклади	Чи має сенс дія
можна вплинути	знижка, швидкість тарифу, час відповіді підтримки, автоплатіж	так — якщо є підстави вважати зв'язок причинним
не можна вплинути	вік, місто, стаж обслуговування	ні
наслідок чогось іншого	філія, день підключення (закодоване правило обліку)	ні, і це найнебезпечніший випадок

Крок 13. Lift

Відділ утримання може обдзвонити 100 клієнтів на тиждень. Відсортуйте перевіркову частину за ризиком, візьміть перші 100 і порівняйте частку відтоку серед них із часткою в усій вибірці.

> AUC описує модель на всьому діапазоні порогів. Замовник працює в ОДНІЙ точці цього діапазону — там, де в нього вистачає людей на обдзвін. Звітуйте обидва числа.

5. Вимоги до звіту

Звіт пишеться просто в ноутбуці, у комірці розділу 15. Відповідайте **числами зі своїх обчислень**, а не загальними словами: «AUC помітно впала» не зараховується, «AUC впала з 0,919 до 0,843» зараховується.

№	Питання
1	Яку метрику ви обрали і чому саме її? Яку точність дала б модель «ніхто не піде» на ваших даних?
2	Назвіть усі стовпці, які ви викинули, і для кожного — момент часу, у який він з'являється. Який із них детектор не знайшов і чому?
3	Яке ваше чесне число і який у нього розкид? Що означає цей розкид для порівняння двох моделей, що відрізняються на 0,004?
4	Чи є у ваших даних артефакт збору? Наведіть AUC передбачення джерела і скажіть, чи можна цій моделі довіряти в іншій філії.
5	Що дало більше — нові ознаки чи складніша модель? Наведіть обидва прирости з довірчими інтервалами і час обчислень.
6	Яку ознаку вбудована важливість назвала важливою помилково? Чому дерева так роблять?
7	Що сталося з дубльованою парою при перестановочній важливості і чому це не вада методу?
8	Яка ознака має немонотонний вплив? Чи побачила б його логістична регресія без вашого втручання?
9	Де PDP збрехав через усереднення і що показав ICE?
10	Наведіть приклад ознаки з великим внеском за Шеплі, втручання в яку нічого не дасть.
11	Що ви скажете замовникові, який просить за цією моделлю обдзвонити 100 клієнтів? Назвіть lift і одне застереження.

5.1. Декларація про використання штучного інтелекту

Зазначте, чи користувались ШІ-асистентом, для чого саме і що перевіряли самостійно. Використання дозволене; **невказане** використання — ні.

> Типова ситуація, через яку це правило існує: асистент пропонує прибрати всі стовпці, що корелюють із ціллю. Разом із витоком зникають справжні ознаки, і робота втрачає сенс. Відповідальність за кожне рішення у ноутбуці лишається на вас, незалежно від того, хто його запропонував.

6. Критерії оцінювання

Максимум 4 бали.

6.1. Частина 1 — конвеєр (2,0 бала)

Пункт	Що має бути	Балів
1.1	Тип задачі, метрика, схема — з обґрунтуванням; метрика не «точність» без порівняння з тривіальною відповіддю	0,25
2.2	Знайдено всі три проблеми даних; для пропусків пояснено **зміст** їх наявності	0,25
3.1–3.2	`to_number` не перетворює дату на число; уся обробка **всередині** конвеєра	0,50
5.1–5.2	Детектор працює, поріг на розмір групи присутній; цільовий витік знайдено повністю	0,25
5.3	**Знайдено оцінку людини** і пояснено, чому детектор її не бачить	0,50
6.1–6.3	Артефакт збору виявлено, передбачення джерела обчислено, драбина зведена	0,25

> Найважливіший рядок — 5.3. Робота, у якій студент зупинився на AUC близько 0,92 і не знайшов оцінку людини, не може отримати більше 1,0 бала за першу частину, яким би охайним не був код. Це і є головне вміння, заради якого робота існує.

6.2. Частина 2 — інтерпретація (1,5 бала)

Пункт	Що має бути	Балів
9.1–9.2	Обидві важливості обчислено, дамі-стовпці згорнуто до вихідних ознак, перестановочна рахується на **перевірковій** частині	0,25
9.3	Знайдено шумну ознаку в топі вбудованої важливості; пояснення через кількість можливих порогів	0,25
9.4	Знайдено дубльовану пару; проведено дослід із вилученням; пояснено, що метод не бреше	0,25
10.2	Немонотонна ознака знайдена; показано, що лінійна модель її не бачить; побудовано ознаку й виміряно приріст	0,25
10.3	Взаємодія виявлена через ICE або PDP по підгрупах; сформульовано дію для бізнесу	0,25
11.3–11.4	Пояснення для одного клієнта людською мовою; наведено приклад «внесок ≠ причина»	0,25

6.3. Частина 3 — звіт (0,5 бала)

Пункт	Балів
Відповіді числами зі своїх обчислень, а не загальними словами	0,25
П'ята хибна інтерпретація, знайдена самостійно (завдання 12.2)	0,15
Декларація про використання ШІ заповнена	0,10

6.4. Штрафи

За що	Скільки
Ноутбук не виконується згори вниз на чистому ядрі	−0,50
Обробка поза конвеєром (`fit_transform` до розбиття)	−0,50

За що	Скільки
Числа у звіті не збігаються з виводом ноутбука	−0,50
Перестановочна важливість порахована на навчальній частині	−0,25
Відсутня декларація про використання ШІ при очевидних ознаках використання	−0,50

7. Типові помилки

«AUC 0,92 — роботу зроблено»

Найчастіший сценарій. Студент знайшов цільовий витік, зрадів падінню і зупинився. Перевірте себе питанням: **хто і в який момент заповнює кожне поле, яке лишилось у моделі?**

Викинуто все, що корелює з ціллю

Протилежна крайність: разом із витоком зникають справжні ознаки. кількість_звернень_у_підтримку корелює з відтоком — але вона **існує** в момент прогнозу, тож викидати її нема підстав.

Обробка до розбиття

`prep.fit_transform(X)` перед крос-валідацією. Зовні все працює, число завищене. Ознака в коді — виклик `fit` або `fit_transform` поза конвеєром.

Перестановочна важливість на навчальній частині

Дає ту саму картину, що й вбудована, і пастка з шумною ознакою не спрацьовує. Якщо у вас шумна ознака має високу перестановочну важливість — майже напевно причина саме в цьому.

PDP на ознаці з пропусками

Сітка виходить порожньою, графік порожній. Будуйте на підвибірці без пропусків і зазначте це.

«Шеплі показали, що треба перевести клієнта в іншу філію»

Головна змістовна помилка роботи. Значення Шеплі показують, **як модель користується ознакою**, а не що станеться при її зміні. Філія має великий внесок тому, що в ній закодовано правило обліку, а не тому, що філія спричиняє відтік.

> Про списування. Набори даних різні: у кожному варіанті роль кожної пастки грає інший стовпець. Якщо у звіті названо стовпець, якого у вашому варіанті немає в цій ролі, робота не зараховується. Перевіряється автоматично звірянням файлу `lr6_результат_NN.json` із ключем варіантів.

8. Зв'язок із рештою курсу

Звідки / куди	Що саме
лекція 7	конвеєр, витік, схеми перевірки — тут застосовано на новому наборі
лекція 8	перестановочна важливість, графіки часткової залежності, значення Шеплі
лабораторна 7	діагностика моделей: зміщення і дисперсія, криві навчання. Чесний набір ознак із цієї роботи — вхід для неї
лекція 9	вкладена крос-валідація: тут гіперпараметри свідомо не підбирались

9. Джерела

Тема	Де читати
Теорія до цієї роботи	Теоретичний конспект лекції 7, розділи 4–13
Витік даних і типові помилки	scikit-learn: Common pitfalls
Конвеєри та колонкові перетворювачі	scikit-learn: Pipelines
Схеми перевірки	scikit-learn: Cross-validation
Важливість ознак і її пастки	scikit-learn: Permutation importance
Графіки часткової залежності	scikit-learn: Partial dependence and ICE
Значення Шеплі	SHAP: документація

Дані згенеровано для навчальних цілей; збіги з реальними клієнтами будь-якого оператора випадкові.