

Лабораторна робота № 1

Вхідний аналіз набору даних

Дисципліна: Інтелектуальний аналіз та візуалізація даних (СК26) **Тривалість:** 2 год аудиторно + 3 год самостійної роботи · **Максимальна оцінка:** 4 бали

Мета роботи

Пригадати роботу в Jupyter Notebook, бібліотеці `pandas` та побудову графіків - і зробити це не на навчальному прикладі, а на реальному файлі, який ніхто не готував спеціально для вас.

Ця робота виконується **до першої лекції**. Нічого нового знати не потрібно: усе, що знадобиться, ви вже проходили в попередніх курсах. Усі поняття, яких ви тут торкнетесь мимохідь, отримують назви й пояснення на лекціях 3 і 4.

Дані

Файл `20171129_FINAL_FINAL.xlsx`, аркуш `Sheet1` - спостереження космічної погоди за 28 серпня - 22 вересня 2017 року, зібрані з трьох різних джерел.

Файл видається **як є**, рівно в тому вигляді, у якому його колись вивантажили. Ніхто не приводив його до ладу, і саме в цьому сенс: справжні дані здебільшого надходять саме такими.

Що ви маєте зробити

Етап	Зміст	Де
1	Розібратися, що взагалі лежить у файлі	аудиторно
2	Виділити три таблиці й привести їх до робочого вигляду	аудиторно
3	Скласти паспорт даних: що є, чого бракує, що виглядає дивно	аудиторно
4	Об'єднати три таблиці в одну	аудиторно
5	Побудувати п'ять графіків, кожен - відповідь на питання	аудиторно + самостійно
6	Порівняти два графіки одних і тих самих даних	самостійно
7	Записати три спостереження про дані	самостійно

Етап	Зміст	Де
8	Декларація про використання інструментів ШІ	самостійно

Що здається

1. Цей файл `.ipynb` із заповненими розв'язками. **Ноутбук має виконуватися згори донизу на чистому ядрі** (Kernel → Restart & Run All) без помилок - це перевіряється першою дією на захисті.
2. Файл `master_hourly.csv` - об'єднана таблиця з етапу 4.
3. Експорт ноутбука у HTML або PDF.
4. Заповнена декларація (етап 8). Без неї фінальна самоперевірка не проходить.

Критерії оцінювання

Бали	Що досягнуто
0	Дані не опрацьовано, графіки не побудовано або побудовано з грубими помилками
1	Таблиці прочитано й кілька графіків побудовано, але типи графіків не відповідають даним, дивних значень не помічено
2	Таблиці розібрано й об'єднано, графіки коректні та підписані, але висновків під ними немає або вони формальні
4	Усе вище виконано, знайдено й пояснено дивні значення, під кожним графіком є змістовний висновок про дані

Головне про оцінку: бали ставляться не за наявність графіка, а за речення під ним. Код, який нічого не пояснює, коштує двох балів з чотирьох.

Нагадування про Jupyter

Якщо давно не працювали - три речі, які знадобляться сьогодні:

- `Shift+Enter` виконує клітинку, `Esc A` / `Esc B` додає клітинку вище / нижче, `Esc M` перетворює клітинку на текстову (Markdown), `Esc Y` - назад на код.
- **Порядок виконання має значення.** Якщо ви правили клітинки в довільному порядку, результат може залежати від історії запусків. Перед здачею обов'язково **Kernel → Restart & Run All** - так ви побачите ноутбук очима викладача.
- Текстові клітинки - не прикраса. Висновки пишуться в них, а не в коментарях до коду.

Крок 0. Ваші дані та варіант

Заповніть три змінні й виконайте обидві клітинки. Друга надрукує **ваше індивідуальне завдання** - воно відрізняється від завдання сусіда.

```
In [1]: ПІБ = 'Козак Наталія'          # напр. 'Шевченко Тарас'
ГРУПА = 'ШІ-34'          # напр. 'КН-31'
ВАРІАНТ = 6              # ваш номер за списком групи

assert ПІБ and ГРУПА and ВАРІАНТ, 'Заповніть ПІБ, ГРУПУ та ВАРІАНТ'
```

```
In [2]: # --- клітинку не редагувати: вона видає ваше персональне завдання -----
ПОТОКИ = ['P>1', 'P>5', 'P>10', 'P>30', 'P>50', 'P>100', 'E>0.8', 'E>2.0']

ПАРИ = [('швидкість вітру', 'густина вітру'),
         ('швидкість вітру', 'потік P>10'),
         ('густина вітру', 'потік P>1'),
         ('радіопотік F10.7', 'потік P>10'),
         ('радіопотік F10.7', 'швидкість вітру'),
         ('потік E>0.8', 'потік P>10')]

АГРЕГАТИ = ['середнє', 'максимум', 'медіана', 'мінімум']

ПИТАННЯ = [
    'Скільки годин за все вікно ваш потік перевищував своє власне медіанне значення',
    'У яку добу середнє значення вашого потоку було найбільшим? А найменшим?',
    'О котрій годині доби потік E>0.8 у середньому найбільший? Побудуйте графік сер',
    'Яка частка рядків об'єднаної таблиці має пропуск хоча б в одному стовпці?',
    'У який день радіопотік F10.7 був найбільшим і чи збігається цей день з піком в',
    'Порівняйте медіану вашого потоку за перший і за другий тиждень спостережень. У',
    'Скільки годин поспіль тривала найдовша неперервна серія «активних» годин (груп',
    'Який зі стовпців об'єднаної таблиці має найбільший розкид відносно власного се',
    'Яку частку сумарного значення вашого потоку за все вікно дали 24 години навкол',
    'Скільки різних діб потрапило у групу «активні» і скільки - у групу «дуже актив',
]

i = int(ВАРІАНТ)
завдання = {
    'ваш потік': ПОТОКИ[(i * 3 + 1) % 8],
    'ваша пара для графіка 3': ' та '.join(ПАРИ[(i * 5 + 2) % 6]),
    'ваш агрегат для етапу 4': АГРЕГАТИ[(i * 5 + 1) % 4],
    'ваше додаткове питання': ПИТАННЯ[(i * 11 + 5) % 10],
}

print('ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · %s, %s, варіант %d' % (ПІБ, ГРУПА, i))
print('=' * 78)
for k, v in завдання.items():
    print('%-28s %s' % (k + ': ', v))
```

ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · Козак Наталія, ШІ-34, варіант 6

=====

ваш потік:	$P > 30$
ваша пара для графіка 3:	густина вітру та потік $P > 1$
ваш агрегат для етапу 4:	мінімум
ваше додаткове питання:	У яку добу середнє значення вашого потоку було найбільш им? А найменшим?

Далі за текстом «**ваш потік**» означає стовпець, названий у першому рядку завдання.

```
In [3]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

pd.set_option('display.width', 200)
pd.set_option('display.max_columns', 40)
plt.rcParams.update({'figure.dpi': 110, 'axes.spines.top': False,
                    'axes.spines.right': False, 'font.size': 9})

MY_FILE = '20171129_FINAL_FINAL.xlsx'
```

Етап 1. Що взагалі лежить у файлі

Перше правило роботи з незнайомими даними: спершу подивитися, потім рахувати.

Завдання 1.1

Спробуйте прочитати аркуш `Sheet1` звичайним способом - `pd.read_excel(ФАЙЛ)` - і виведіть перші рядки та типи стовпців.

Очікуваний результат: результат буде дивним. Подивіться на назви стовпців і на те, які там типи даних. Поясніть у наступній клітинці, чому так вийшло.

```
In [4]: # ВАШ КОД
df = pd.read_excel(MY_FILE)
print(df.head())
df.info()
```

```

      Unnamed: 0      ftp://ftp.swpc.noaa.gov/pub/lists/particle/ Unnamed: 2 Unnamed:
3 Unnamed: 4 Unnamed: 5 Unnamed: 6 Unnamed: 7 Unnamed: 8 Unnamed: 9 Unnamed: 10 Unna
med: 11 Unnamed: 12 \
0      NaN      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
NaN      NaN
1      NaN      :Data_list: 20170901_Gs_part_5m.txt      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
NaN      NaN
2      NaN      :Created: 2017 Sep 02 0011 UTC      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
NaN      NaN
3      NaN # Prepared by the U.S. Dept. of Commerce, NOAA...      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
NaN      NaN
4      NaN # Please send comments and suggestions to SWPC...      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
NaN      NaN

```

```

      Unnamed: 13 Unnamed: 14 Unnamed: 15 Unnamed: 16 Unnamed: 17 Unnamed: 18 Unnamed:
19 Unnamed: 20 Unnamed: 21 Unnamed: 22 Unnamed: 23 Unnamed: 24 Unnamed: 25 \
0      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
1      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
2      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
3      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN
4      NaN      NaN      NaN      NaN      NaN      NaN      NaN      N
aN      NaN      NaN      NaN      NaN      NaN      NaN      NaN

```

```

      http://umtof.umd.edu/pm/crn/ Unnamed: 27 Unnamed: 28 Unname
d: 29 Unnamed: 30 Unnamed: 31

```

```

0      NaN      NaN      NaN
NaN      NaN      NaN
1      SOHO CELIAS Proton Monitor      NaN      NaN
NaN      NaN      NaN
2      Solar Wind Parameters for Carrington Rotation ...      NaN      NaN
NaN      NaN      NaN
3      Proton speed [km/sec]      NaN      NaN
NaN      NaN      NaN
4      Proton density [protons per cubic centimeter]      NaN      NaN
NaN      NaN      NaN

```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 7225 entries, 0 to 7224
```

```
Data columns (total 32 columns):
```

#	Column	Non-Null Count	Dtype
0	Unnamed: 0	0 non-null	float64
1	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	7222 non-null	object
2	Unnamed: 2	7202 non-null	object
3	Unnamed: 3	7202 non-null	object
4	Unnamed: 4	7202 non-null	object
5	Unnamed: 5	7203 non-null	object
6	Unnamed: 6	7203 non-null	object

```

7    Unnamed: 7          7198 non-null    object
8    Unnamed: 8          7198 non-null    object
9    Unnamed: 9          7198 non-null    object
10   Unnamed: 10         7198 non-null    object
11   Unnamed: 11         7198 non-null    object
12   Unnamed: 12         7198 non-null    object
13   Unnamed: 13         7198 non-null    object
14   Unnamed: 14         7198 non-null    object
15   Unnamed: 15          0 non-null    float64
16   Unnamed: 16          32 non-null    object
17   Unnamed: 17          26 non-null    object
18   Unnamed: 18          26 non-null    object
19   Unnamed: 19          26 non-null    object
20   Unnamed: 20          0 non-null    float64
21   Unnamed: 21          0 non-null    float64
22   Unnamed: 22          0 non-null    float64
23   Unnamed: 23          0 non-null    float64
24   Unnamed: 24         601 non-null    float64
25   Unnamed: 25         601 non-null    float64
26   http://umtof.umd.edu/pm/crn/    607 non-null    object
27   Unnamed: 27          602 non-null    object
28   Unnamed: 28          602 non-null    object
29   Unnamed: 29          602 non-null    object
30   Unnamed: 30          602 non-null    object
31   Unnamed: 31          602 non-null    object

```

dtypes: float64(8), object(24)

memory usage: 1.8+ MB

Відповідь 1.1: (чому звичайне читання дало саме такий результат)

бо pandas читає все як одну велику таблицю: перші рядки, як заголовок, відповідно майже всі Unnamed, і пусті клітинки - Nan

Завдання 1.2

Прочитайте аркуш ще раз, але **без заголовка**: `pd.read_excel(ФАЙЛ, header=None)`. Виведіть його розмір і подивіться на перші 30 рядків.

```

In [5]: # ВАШ КОД
RAW = pd.read_excel(MY_FILE, header=None)
print(RAW.shape)
print(RAW.head(30))

```

(7226, 32)

0	1	2	3	4	5
6	7	8	9	10	11
0	NaN	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	NaN	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
2	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
3	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
4	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
5	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
6	NaN	#	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
7	NaN	# Label: P > 1 = Particles at >1 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
8	NaN	# Label: P > 5 = Particles at >5 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
9	NaN	# Label: P >10 = Particles at >10 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
10	NaN	# Label: P >30 = Particles at >30 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
11	NaN	# Label: P >50 = Particles at >50 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
12	NaN	# Label: P>100 = Particles at >100 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
13	NaN	# Label: E>0.8 = Electrons at >0.8 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
14	NaN	# Label: E>2.0 = Electrons at >2.0 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
15	NaN	# Label: E>4.0 = Electrons at >4.0 Mev	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
16	NaN	# Units: Particles = Protons/cm2-s-sr	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
17	NaN	# Units: Electrons = Electrons/cm2-s-sr	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
18	NaN	# Source: GOES-15	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
19	NaN	# Location: W135	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
20	NaN	# Missing data: -1.00e+05	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
21	NaN	NaN	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
22	NaN	5-minute GOES-15 Solar Particle and Electron ...	NaN	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN
23	NaN	NaN	NaN	NaN	Modified
Seconds	NaN	NaN	NaN	NaN	NaN
24	NaN	# UT C D ate Time	NaN	NaN	Julian
of the	NaN	NaN	NaN	NaN	NaN
25	NaN	# YR MO DA HHMM	NaN	NaN	Day
Day	P > 1	P > 5	P >10	P >30	P >50
26	NaN	2017	8	28	0
					57993

0	12	0.26	0.18	0.114	0.104	0.0793	23600	1180	NaN										
27	NaN							2017	8	28	5	57993							
300	19.4	0.69	0.314	0.112	0.0612	0.0251	23100	1160	NaN										
28	NaN							2017	8	28	10	57993							
600	8.48	0.168	0.13	0.0717	0.0614	0.0304	22200	1090	NaN										
29	NaN							2017	8	28	15	57993							
900	15.4	0.566	0.198	0.0926	0.0568	0.0251	20400	997	NaN										
								16	17	18								19	
20	21	22	23	24	25							26	27	2					
8	29		30		31														
0								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		http://umtof.umd.edu/pm/crn/									NaN	N	
aN	NaN		NaN		NaN														
1								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
2								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		SOHO CELIAS Proton Monitor									NaN	N	
aN	NaN		NaN		NaN														
3								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		Solar Wind Parameters for Carrington Rotation ...									NaN	N	
aN	NaN		NaN		NaN														
4								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		Proton speed [km/sec]									NaN	N	
aN	NaN		NaN		NaN														
5								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		Proton density [protons per cubic centimeter]									NaN	N	
aN	NaN		NaN		NaN														
6								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
7								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN		Measurement time (Year, Month, Day of Month, D...									NaN	N	
aN	NaN		NaN		NaN														
8								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
9								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
10								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
11								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
12								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
13	ftp://ftp.swpc.noaa.gov/pub/indices/old_indice...								NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														
14								NaN	NaN	NaN								NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN						NaN	NaN	N					
aN	NaN		NaN		NaN														

```

15      Product: Daily Solar Data      quar_DSD.txt      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
16      :Issued: 0825 UT 04 Oct 2017      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
17      #      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
18 # Prepared by the U.S. Dept. of Commerce, NOA...      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
19 # Please send comments and suggestions to SWP...      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
20      NaN      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
21      NaN      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
22      NaN      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
23      Quarterly Daily Solar Data      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
24      NaN      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
25      NaN      NaN      NaN      NaN
NaN NaN NaN NaN NaN NaN      NaN NaN N
aN NaN NaN NaN
26      NaN      Month      Date      Radio Flux 10.7
NaN NaN NaN NaN NaN NaN      # YR      MO
DA HH SPEED DENSITY
27      2017      8      28      82
NaN NaN NaN NaN 0.0 0.0      17 8
28 0 285 3
28      2017      8      29      84
NaN NaN NaN NaN 1.0 1.0      17 8
28 1 305 3.4
29      2017      8      30      87
NaN NaN NaN NaN 2.0 2.0      17 8
28 2 309 1.7

```

Завдання 1.3

Для кожного стовпця порахуйте, скільки в ньому заповнених клітинок
(`RAW.notna().sum()`), і виведіть результат.

Очікуваний результат: 32 числа. Серед них будуть нулі та згустки великих значень.
За цими згустками видно, що в аркуші **не одна таблиця, а кілька**, вставлені поруч.

Питання: скільки таблиць в аркуші і які стовпці займає кожна?

```
In [6]: # ВАШ КОД
print(RAW.notna().sum())
```

```
0      0
1    7223
2    7202
3    7202
4    7202
5    7203
6    7203
7    7198
8    7198
9    7198
10   7198
11   7198
12   7198
13   7198
14   7198
15      0
16     32
17     26
18     26
19     26
20      0
21      0
22      0
23      0
24    601
25    601
26    608
27    602
28    602
29    602
30    602
31    602
dtype: int64
```

Відповідь 1.3: (скільки таблиць і які стовпці кожна займає)

три таблиці: 2-15, 17-20, 25-32 - нумерація з одиниці

Завдання 1.4

Над кожною таблицею є кілька текстових рядків - це службовий опис від тих, хто дані збирав. Виведіть їх і випишіть для кожної таблиці **джерело даних та одиниці вимірювання**.

Це найкорисніші п'ять хвилин роботи: жодної з цих відомостей у самій таблиці немає, і без них ви не знатимете, у чому вимірюєте.

```
In [7]: # ВАШ КОД
for col in [1, 16, 26]:
    print(f"\nColumn {col}:")
    for index, value in RAW.iloc[:, col].dropna().head(20).items():
        print(f"{index}: {value}")
```

Column 1:

```

0: ftp://ftp.swpc.noaa.gov/pub/lists/particle/
2: :Data_list: 20170901_Gs_part_5m.txt
3: :Created: 2017 Sep 02 0011 UTC
4: # Prepared by the U.S. Dept. of Commerce, NOAA, Space Weather Prediction Center
5: # Please send comments and suggestions to SWPC.Webmaster@noaa.gov
6: #
7: # Label: P > 1 = Particles at >1 Mev
8: # Label: P > 5 = Particles at >5 Mev
9: # Label: P >10 = Particles at >10 Mev
10: # Label: P >30 = Particles at >30 Mev
11: # Label: P >50 = Particles at >50 Mev
12: # Label: P>100 = Particles at >100 Mev
13: # Label: E>0.8 = Electrons at >0.8 Mev
14: # Label: E>2.0 = Electrons at >2.0 Mev
15: # Label: E>4.0 = Electrons at >4.0 Mev
16: # Units: Particles = Protons/cm2-s-sr
17: # Units: Electrons = Electrons/cm2-s-sr
18: # Source: GOES-15
19: # Location: W135
20: # Missing data: -1.00e+05

```

Column 16:

```

13: ftp://ftp.swpc.noaa.gov/pub/indices/old_indices/2017Q3_DSD.txt
15: Product: Daily Solar Data          quar_DSD.txt
16: :Issued: 0825 UT 04 Oct 2017
17: #
18: # Prepared by the U.S. Dept. of Commerce, NOAA, Space Weather Prediction Center
19: # Please send comments and suggestions to SWPC.Webmaster@noaa.gov
23: Quarterly Daily Solar Data
27: 2017
28: 2017
29: 2017
30: 2017
31: 2017
32: 2017
33: 2017
34: 2017
35: 2017
36: 2017
37: 2017
38: 2017
39: 2017

```

Column 26:

```

0: http://umtof.umd.edu/pm/crn/
2: SOHO CELIAS Proton Monitor
3: Solar Wind Parameters for Carrington Rotation (hour averages)
4: Proton speed [km/sec]
5: Proton density [protons per cubic centimeter]
7: Measurement time (Year, Month, Day of Month, Day of Year, Hour, Minute, Second)
26: # YR
27: 17
28: 17
29: 17
30: 17

```

31: 17
 32: 17
 33: 17
 34: 17
 35: 17
 36: 17
 37: 17
 38: 17
 39: 17

Відповідь 1.4:

Таблиця	Джерело	Одиниці вимірювання
A	GOES-15	Particles = Protons/cm2-s-sr, Electrons = Electrons/cm2-s-sr
B	Space Weather Prediction Center	-
C	SOHO CELIAS Proton Monitor	Proton speed [km/sec], Proton density [protons per cubic centimeter],

Етап 2. Три таблиці в робочому вигляді

У файлі три таблиці. Ось що в них лежить - решту ви вже знайшли самі:

Таблиця	Стовпці аркуша	Що це	Один рядок =
A	B-O	вимірювання із супутника GOES-15: потоки частинок різної енергії	5 хвилин
B	Q-T	добовий показник сонячної активності F10.7	доба
C	Y-AF	швидкість і густина сонячного вітру	година

Завдання 2.1

Виділіть кожну таблицю в окремий `DataFrame` - назвіть їх `A`, `B` і `C`. Дайте стовпцям осмислені назви й перетворіть значення на числа (`pd.to_numeric(..., errors='coerce')` стане в пригоді).

```
In [8]: # ВАШ КОД
A = RAW.iloc[26:, 1:15].copy()
B = RAW.iloc[27:, 16:20].copy()
C = RAW.iloc[27:, 24:32].copy()

A.columns = ['year', 'month', 'day', 'hhmm', 'modified_julian_day',
             'seconds_of_day', 'P>1', 'P>5', 'P>10', 'P>30',
```

```

        'P>50', 'P>100', 'E>0.8', 'E>2.0']
B.columns = ['year', 'month', 'day', 'F10.7']
C.columns = ['hour_1', 'hour_2', 'year', 'month', 'day',
             'hour', 'speed_km_s', 'density_protons_cm3']

A = A.apply(pd.to_numeric, errors='coerce').dropna(how='all').reset_index(drop=True)
B = B.apply(pd.to_numeric, errors='coerce').dropna(how='all').reset_index(drop=True)
C = C.apply(pd.to_numeric, errors='coerce').dropna(how='all').reset_index(drop=True)

for name, table in [('A', A), ('B', B), ('C', C)]:
    print(f'Таблиця {name}: {table.shape}')
    print(table.head())

```

Таблиця A: (7200, 14)

	year	month	day	hhmm	modified_julian_day	seconds_of_day	P>1	P>5	P>10
P>30	P>50	P>100	E>0.8	E>2.0					
0	2017	8	28	0	57993	0	12.00	0.260	0.180
0.1140	0.1040	0.0793	23600.0	1180.0					
1	2017	8	28	5	57993	300	19.40	0.690	0.314
0.1120	0.0612	0.0251	23100.0	1160.0					
2	2017	8	28	10	57993	600	8.48	0.168	0.130
0.0717	0.0614	0.0304	22200.0	1090.0					
3	2017	8	28	15	57993	900	15.40	0.566	0.198
0.0926	0.0568	0.0251	20400.0	997.0					
4	2017	8	28	20	57993	1200	6.41	0.156	0.118
0.0597	0.0494	0.0251	18500.0	875.0					

Таблиця B: (25, 4)

	year	month	day	F10.7
0	2017.0	8.0	28.0	82.0
1	2017.0	8.0	29.0	84.0
2	2017.0	8.0	30.0	87.0
3	2017.0	8.0	31.0	92.0
4	2017.0	9.0	1.0	93.0

Таблиця C: (601, 8)

	hour_1	hour_2	year	month	day	hour	speed_km_s	density_protons_cm3
0	0.0	0.0	17.0	8.0	28.0	0.0	285.0	3.0
1	1.0	1.0	17.0	8.0	28.0	1.0	305.0	3.4
2	2.0	2.0	17.0	8.0	28.0	2.0	309.0	1.7
3	3.0	3.0	17.0	8.0	28.0	3.0	304.0	2.0
4	4.0	4.0	17.0	8.0	28.0	4.0	302.0	2.3

Завдання 2.2

У кожній таблиці дата й час записані **по-різному** й розкидані по кількох стовпцях.

Зберіть для кожної таблиці один стовпець `ts` типу `datetime`.

Після цього обов'язково виведіть для кожної таблиці найранішу й найпізнішу дату.

Очікуваний результат: усі три таблиці мають лежати в межах серпня-вересня 2017 року. Якщо у вас вийшов інший рік - придивіться, як записано рік у тій таблиці, і виправте.

```

In [9]: # A: час записаний як hhmm, наприклад 1235 означає 12:35
A['ts'] = pd.to_datetime(A[['year', 'month', 'day']])

```

```

A['ts'] += pd.to_timedelta(A['hhmm'] // 100, unit='h')
A['ts'] += pd.to_timedelta(A['hhmm'] % 100, unit='m')

# B: є тільки дата, тому час буде 00:00
B['ts'] = pd.to_datetime(B[['year', 'month', 'day']])

# C: рік записаний як 17, тому додаю 2000
C['ts'] = pd.to_datetime(C[['year', 'month', 'day']].assign(year=C['year'] + 2000))
C['ts'] += pd.to_timedelta(C['hour'], unit='h')

for name, table in [('A', A), ('B', B), ('C', C)]:
    print(f"Таблиця {name}: від {table['ts'].min()} до {table['ts'].max()}")

```

Таблиця A: від 2017-08-28 00:00:00 до 2017-09-21 23:55:00

Таблиця B: від 2017-08-28 00:00:00 до 2017-09-21 00:00:00

Таблиця C: від 2017-08-28 00:00:00 до 2017-09-22 00:00:00

Таблиця C: від 2017-08-28 00:00:00 до 2017-09-22 00:00:00

Самоперевірка етапу 2. Клітинка має виконатися без помилок.

```

In [10]: assert len(A) == 7200, 'у таблиці A має бути 7200 рядків, а є %d' % len(A)
assert len(B) == 25, 'у таблиці B має бути 25 рядків, а є %d' % len(B)
assert len(C) == 601, 'у таблиці C має бути 601 рядок, а є %d' % len(C)
for назва, т in [('A', A), ('B', B), ('C', C)]:
    рік = pd.to_datetime(т['ts']).dt.year
    assert рік.min() == 2017 and рік.max() == 2017, 'у таблиці %s рік не 2017 - пер
print('Етап 2 пройдено')

```

Етап 2 пройдено

Етап 3. Паспорт даних

Завдання 3.1

Для кожної таблиці виведіть: розмір, типи стовпців, кількість пропусків у кожному стовпці, кількість повних дублікатів рядків і описові статистики (`describe()`).

```

In [11]: for name, table in [('A', A), ('B', B), ('C', C)]:
    print(f'\nТаблиця {name}')
    print('Розмір:', table.shape)
    print('\nТипи стовпців:')
    print(table.dtypes)
    print('\nКількість пропусків:')
    print(table.isna().sum())
    print('\nКількість повних дублікатів:', table.duplicated().sum())
    print('\nОписова статистика:')
    print(table.describe())

```

Таблиця А
Розмір: (7200, 15)

Типи стовпців:

year	int64
month	int64
day	int64
hhmm	int64
modified_julian_day	int64
seconds_of_day	int64
P>1	float64
P>5	float64
P>10	float64
P>30	float64
P>50	float64
P>100	float64
E>0.8	float64
E>2.0	float64
ts	datetime64[ns]

dtype: object

Кількість пропусків:

year	0
month	0
day	0
hhmm	0
modified_julian_day	0
seconds_of_day	0
P>1	3
P>5	3
P>10	3
P>30	3
P>50	3
P>100	3
E>0.8	3
E>2.0	3
ts	0

dtype: int64

Кількість повних дублікатів: 0

Описова статистика:

	year	month	day	hhmm	modified_julian_day	seconds_o
f_day	P>1	P>5	P>10	P>30	P>50	P>100
E>0.8	E>2.0	\				
count	7200.0	7200.000000	7200.000000	7200.000000	7200.000000	7200.000000
mean	2017.0	8.840000	13.960000	1177.500000	58005.000000	43050.000000
min	2017.0	8.000000	1.000000	0.000000	57993.000000	0.000000
25%	2017.0	9.000000	7.000000	588.750000	57999.000000	21525.000000
	11.700000	0.279000	0.186000	0.098400	0.059700	0.026300

```

22200.000000      552.000000
50%    2017.0      9.000000    13.000000    1177.500000      58005.000000    43050.0
00000    55.400000    0.632000    0.376000    0.146000    0.086600    0.03630
68600.000000    4290.000000
75%    2017.0      9.000000    19.000000    1766.250000      58011.000000    64575.0
00000    560.000000    107.000000    35.800000    0.990000    0.249000    0.06700
143000.000000    14100.000000
max    2017.0      9.000000    31.000000    2355.000000      58017.000000    86100.0
00000    32500.000000    2890.000000    1330.000000    399.000000    191.000000    61.50000
259000.000000    110000.000000
std      0.0      0.366632      8.775483      692.481902      7.211603      24943.1
13498    1625.968447    390.921861    222.362627      67.265595      28.620524      7.15889
65728.005824    16920.617446

```

```

                                ts
count                          7200
mean    2017-09-09 11:57:30
min      2017-08-28 00:00:00
25%      2017-09-03 05:58:45
50%      2017-09-09 11:57:30
75%      2017-09-15 17:56:15
max      2017-09-21 23:55:00
std                               NaN

```

Таблиця В
Розмір: (25, 5)

Типи стовпців:

```

year          float64
month         float64
day           float64
F10.7         float64
ts            datetime64[ns]
dtype: object

```

Кількість пропусків:

```

year      0
month     0
day       0
F10.7     0
ts        0
dtype: int64

```

Кількість повних дублікатів: 0

Описова статистика:

```

      year      month      day      F10.7      ts
count    25.0    25.000000    25.000000    25.000000      25
mean    2017.0     8.840000    13.960000    92.680000    2017-09-09 00:00:00
min     2017.0     8.000000     1.000000    71.000000    2017-08-28 00:00:00
25%     2017.0     9.000000     7.000000    74.000000    2017-09-03 00:00:00
50%     2017.0     9.000000    13.000000    84.000000    2017-09-09 00:00:00
75%     2017.0     9.000000    19.000000   107.000000    2017-09-15 00:00:00
max     2017.0     9.000000    31.000000   140.000000    2017-09-21 00:00:00
std        0.0     0.374166     8.955817    22.206831      NaN

```

Таблиця C
Розмір: (601, 9)

Типи стовпців:

```
hour_1          float64
hour_2          float64
year            float64
month           float64
day             float64
hour            float64
speed_km_s      float64
density_protons_cm3 float64
ts              datetime64[ns]
dtype: object
```

Кількість пропусків:

```
hour_1      0
hour_2      0
year        0
month       0
day         0
hour        0
speed_km_s  0
density_protons_cm3 0
ts          0
dtype: int64
```

Кількість повних дублікатів: 0

Описова статистика:

	hour_1	hour_2	year	month	day	hour	speed_km_s
density_protons_cm3				ts			
count	601.000000	601.000000	601.0	601.000000	601.000000	601.000000	601.000000
	601.000000		601				
mean	11.480865	11.480865	17.0	8.840266	13.973378	11.480865	506.547421
	2.907654	2017-09-09 12:00:00					
min	0.000000	0.000000	17.0	8.000000	1.000000	0.000000	-1.000000
	-1.000000	2017-08-28 00:00:00					
25%	5.000000	5.000000	17.0	9.000000	7.000000	5.000000	447.000000
	1.800000	2017-09-03 06:00:00					
50%	11.000000	11.000000	17.0	9.000000	13.000000	11.000000	517.000000
	2.400000	2017-09-09 12:00:00					
75%	17.000000	17.000000	17.0	9.000000	19.000000	17.000000	584.000000
	3.400000	2017-09-15 18:00:00					
max	23.000000	23.000000	17.0	9.000000	31.000000	23.000000	806.000000
	31.700000	2017-09-22 00:00:00					
std	6.938063	6.938063	0.0	0.366664	8.781000	6.938063	125.073291
	2.637873		NaN				

Завдання 3.2 - дивні значення

Подивіться на рядок `min` у таблиці `describe()` для таблиці C.

Швидкість і густина - фізичні величини, які **не можуть бути від'ємними**. Знайдіть від'ємні значення, порахуйте, скільки їх, і поверніться до службового опису з завдання

1.4: там написано, що вони означають.

Замініть ці значення на `NaN` і покажіть, як після цього змінилися середнє й мінімум.

Очікуваний результат: два числа «до» і «після» для кожного зі стовпців.

```
In [12]: for col in ['speed_km_s', 'density_protons_cm3']:
    negative = C[col] < 0
    print(f'\nСтовпець: {col}')
    print('Кількість від'ємних значень:', negative.sum())
    print('Які це значення:', C.loc[negative, col].unique())

    before = C[col].agg(['mean', 'min'])
    C.loc[negative, col] = np.nan
    after = C[col].agg(['mean', 'min'])

    print(pd.DataFrame({'До заміни': before, 'Після заміни': after}))
```

```
Стовпець: speed_km_s
Кількість від'ємних значень: 8
Які це значення: [-1.]
      До заміни  Після заміни
mean  506.547421   513.394604
min    -1.000000   277.000000
```

```
Стовпець: density_protons_cm3
Кількість від'ємних значень: 8
Які це значення: [-1.]
      До заміни  Після заміни
mean    2.907654    2.960371
min    -1.000000    0.100000
```

Відповідь 3.2:

У швидкості та густині є по 8 від'ємних значень, усі вони дорівнюють -1. У службовому описі пропуски позначені як -1.00e+05 (тобто -100000), але в самій таблиці `C` стоїть -1. Отже, опис і дані не збігаються. Оскільки швидкість і густина не можуть бути від'ємними, ці значення вважаємо пропусками та замінюємо на `NaN`.

Після заміни середня швидкість зросла з 506.55 до 513.39 км/с, а мінімальна - з -1 до 277 км/с. Середня густина зросла з 2.91 до 2.96 протонів/см³, а мінімальна - з -1 до 0.1 протонів/см³. Від'ємні значення знижували середнє, бо враховувалися як справжні вимірювання. Після заміни `pandas` не враховує `NaN` під час обчислення середнього та мінімуму.

Завдання 3.3 - питання на подумати

У таблиці `A` є стовпці, для яких `describe()` слухняно рахує середнє й стандартне відхилення, хоча ці числа не мають жодного сенсу.

Знайдіть їх і поясніть своїми словами, чому середнє для них безглузде.

Підказка: не кожне число в таблиці є результатом вимірювання.

Це питання не має однієї «правильної» відповіді з підручника - на нього ви відповідаєте з власного здорового глузду. Формальне пояснення буде на лекції 3.

```
In [13]: time_columns = ['year', 'month', 'day', 'hhmm',
                        'modified_julian_day', 'seconds_of_day']
print(A[time_columns].describe())
```

	year	month	day	hhmm	modified_julian_day	seconds_of_day
count	7200.0	7200.000000	7200.000000	7200.000000	7200.000000	7200.000000
mean	2017.0	8.840000	13.960000	1177.500000	58005.000000	43050.000000
std	0.0	0.366632	8.775483	692.481902	7.211603	24943.13498
min	2017.0	8.000000	1.000000	0.000000	57993.000000	0.000000
25%	2017.0	9.000000	7.000000	588.750000	57999.000000	21525.000000
50%	2017.0	9.000000	13.000000	1177.500000	58005.000000	43050.000000
75%	2017.0	9.000000	19.000000	1766.250000	58011.000000	64575.000000
max	2017.0	9.000000	31.000000	2355.000000	58017.000000	86100.000000

Відповідь 3.3:

Це `year`, `month`, `day` і `hhmm`. Вони записані числами, але показують, коли зробили вимірювання. Наприклад, середнє між серпнем (8) і вереснем (9) - 8.5, але такого місяця немає. Середній номер дня теж мало що пояснює, бо 1 вересня йде після 31 серпня, хоча число 1 менше за 31.

З `hhmm` це ще помітніше: між 09:50 і 10:10 середній час - 10:00, а середнє чисел 950 і 1010 дорівнює 980. Виходить 09:80 - такого часу взагалі немає. Середнє року тут просто буде 2017, а стандартне відхилення - 0, бо всі записи за один рік. Про космічну погоду це нічого не говорить.

`modified_julian_day` і `seconds_of_day` теж описують час, а не потоки частинок. Для них середнє можна обчислити й пояснити як середній момент часу, але для аналізу самих вимірювань воно тут не потрібне. Корисніше подивитися початок і кінець спостережень через `ts`.

Етап 4. Об'єднання трьох таблиць в одну

Таблиці мають різний крок у часі: 5 хвилин, година і доба. Щоб працювати з ними разом, потрібна спільна сітка. Беремо **годину**.

Кожна таблиця потребує своєї дії:

1. **A: 5 хвилин** → **година**. Кілька рядків згортаються в один - це `resample` + агрегація.
2. **C: уже година**. Просте з'єднання по спільному стовпцю `ts` - `merge`.
3. **B: доба** → **година**. Навпаки, одне значення розтягується на 24 години доби.

Завдання 4.1

Зведіть таблицю A до погодинної сітки. Для кожного потоку порахуйте **два** числа за годину: середнє і максимум.

```
In [14]: flows = ['P>1', 'P>5', 'P>10', 'P>30', 'P>50', 'P>100', 'E>0.8', 'E>2.0']

A_hourly = A.set_index('ts')[flows].resample('h').agg(['mean', 'max'])

A_hourly.columns = [f'{flow}_{stat}' for flow, stat in A_hourly.columns]
A_hourly = A_hourly.reset_index()

print('Розмір погодинної таблиці:', A_hourly.shape)
print(A_hourly.head())
```

Розмір погодинної таблиці: (600, 17)

	ts	P>1_mean	P>1_max	P>5_mean	P>5_max	P>10_mean	P>10_max	P>30_mean	P>30_max	P>50_mean	P>50_max	P>100_mean	P>100_max	E>0.8_mean	E>0.8_max	E>2.0_mean	E>2.0_max
0	2017-08-28 00:00:00	9.778333	19.40	0.324917	0.690	0.192917	0.314	0.098850	0.2240	0.077583	0.1780	0.040692	0.0793	20941.666667	2360	0.0	1011.583333
1	2017-08-28 01:00:00	7.994167	13.60	0.291667	0.512	0.156583	0.259	0.072583	0.0919	0.058700	0.0798	0.029950	0.0471	18091.666667	2060	0.0	713.000000
2	2017-08-28 02:00:00	6.099167	10.80	0.283000	0.479	0.177667	0.321	0.084450	0.1210	0.069642	0.1110	0.035025	0.0595	14108.333333	1500	0.0	380.833333
3	2017-08-28 03:00:00	4.752500	7.76	0.236833	0.329	0.166333	0.244	0.087658	0.1800	0.068092	0.1390	0.035517	0.0818	12766.666667	1310	0.0	267.916667
4	2017-08-28 04:00:00	4.158333	6.62	0.334917	0.539	0.208333	0.309	0.084800	0.1530	0.072850	0.1420	0.039708	0.0694	11333.333333	1230	0.0	203.000000

Завдання 4.2

У вашому завданні названо агрегат (`середнє` , `максимум` , `медіана` або `мінімум`).

Візьміть ваш потік за одну добу, порахуйте для нього по годинах ваш агрегат і ще один на ваш вибір, і побудуйте обидві криві на одному графіку.

Питання: чим вони відрізняються і в якій ситуації різниця між ними стане суттєвою?

```
In [15]: # Для варіанта 6 потік - P>30, агрегат - мінімум
flow = завдання['ваш потік']
day = A[(A['ts'] >= '2017-09-10') & (A['ts'] < '2017-09-11')]

comparison = day.set_index('ts')[flow].resample('h').agg(['min', 'max'])
print(comparison)

plt.figure(figsize=(10, 4))
plt.plot(comparison.index.hour, comparison['min'], label='Мінімум', marker='o')
plt.plot(comparison.index.hour, comparison['max'], label='Максимум', marker='o')
plt.title(f'Мінімум і максимум потоку {flow} за годину, 10.09.2017')
plt.xlabel('Година доби')
plt.ylabel('Потік протонів, протонів/(см²·с·ср)')
plt.xticks(range(0, 24, 2))
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

	min	max
ts		
2017-09-10 00:00:00	0.1030	0.292
2017-09-10 01:00:00	0.0729	0.156
2017-09-10 02:00:00	0.0860	0.180
2017-09-10 03:00:00	0.0579	0.196
2017-09-10 04:00:00	0.0596	0.280
2017-09-10 05:00:00	0.0576	0.176
2017-09-10 06:00:00	0.0925	0.319
2017-09-10 07:00:00	0.0975	0.373
2017-09-10 08:00:00	0.0990	0.327
2017-09-10 09:00:00	0.0727	0.209
2017-09-10 10:00:00	0.1190	0.164
2017-09-10 11:00:00	0.0977	0.181
2017-09-10 12:00:00	0.0975	0.151
2017-09-10 13:00:00	0.0975	0.254
2017-09-10 14:00:00	0.0576	0.179
2017-09-10 15:00:00	0.1020	0.193
2017-09-10 16:00:00	0.1420	64.500
2017-09-10 17:00:00	90.1000	217.000
2017-09-10 18:00:00	237.0000	356.000
2017-09-10 19:00:00	240.0000	309.000
2017-09-10 20:00:00	242.0000	275.000
2017-09-10 21:00:00	276.0000	324.000
2017-09-10 22:00:00	328.0000	377.000
2017-09-10 23:00:00	324.0000	351.000



Відповідь 4.2:

Для свого потоку $P > 30$ я порівняла мінімум і максимум за 10 вересня. До 16:00 обидві криві на цьому масштабі майже біля нуля, а потім потік різко зростає. За годину з 16:00 до 17:00 мінімум становить 0.142, а максимум - 64.5. Тобто навіть у межах однієї години значення дуже змінилися.

Мінімум показує найменше значення за годину, а максимум - найбільше. Різниця між ними особливо важлива під час різкого зростання або короткого сплеску: якщо дивитися тільки на мінімум, можна не помітити високих значень. Але й максимум не означає, що такий потік тримався всю годину.

Завдання 4.3

Об'єднайте три таблиці в одну - назвіть її **M**. Виведіть її розмір і всі рядки, у яких є хоча б один пропуск.

Зверніть увагу: таблиці закінчуються не в один і той самий момент. Тому результат залежить від того, який тип об'єднання ви оберете (`how='inner'` чи `how='outer'`). Спробуйте обидва, подивіться, чим відрізняється кількість рядків, і поясніть свій вибір.

```
In [16]: B_hourly = B.loc[B.index.repeat(24), ['ts', 'F10.7']].reset_index(drop=True)
B_hourly['ts'] += pd.to_timedelta(np.tile(np.arange(24), len(B)), unit='h')

C_hourly = C[['ts', 'speed_km_s', 'density_protons_cm3']]

M_inner = A_hourly.merge(C_hourly, on='ts', how='inner')
M_inner = M_inner.merge(B_hourly, on='ts', how='inner')

M_outer = A_hourly.merge(C_hourly, on='ts', how='outer')
M_outer = M_outer.merge(B_hourly, on='ts', how='outer')

print('Кількість рядків з inner:', len(M_inner))
print('Кількість рядків з outer:', len(M_outer))

M = M_outer.sort_values('ts').reset_index(drop=True)
```

```
print('Розмір M:', M.shape)

missing_rows = M[M.isna().any(axis=1)]
print('Рядків з пропусками:', len(missing_rows))
print(missing_rows.to_string(index=False))
```

Кількість рядків з inner: 600

Кількість рядків з outer: 601

Розмір M: (601, 20)

Рядків з пропусками: 9

	ts	P>1_mean	P>1_max	P>5_mean	P>5_max	P>10_mean	P>10_max	P>30_mean	P>30_max	P>50_mean	P>50_max	P>100_mean	P>100_max	E>0.8_mean	E>0.8_max	E>2.0_mean	E>2.0_max	speed_kms	density_protons_cm3	F10.7
2017-09-04 07:00:00	6.465833	10.10	0.262083	0.593	0.171500	0.294	0.0	0.145	0.068558	0.134	0.031717	0.0523	90600.000000	100000.0	7410.833333	8950.0	NaN	NaN	140.0	
2017-09-04 08:00:00	4.010833	5.08	0.256000	0.432	0.195833	0.336	0.0	0.145	0.070033	0.134	0.036492	0.0546	73483.333333	79300.0	5048.333333	5850.0	NaN	NaN	140.0	
2017-09-04 09:00:00	3.268333	4.42	0.303417	0.518	0.220333	0.302	0.1	0.162	0.081975	0.134	0.046483	0.0765	60475.000000	68500.0	3715.833333	4480.0	NaN	NaN	140.0	
2017-09-04 10:00:00	3.179167	4.74	0.252167	0.372	0.181833	0.280	0.1	0.150	0.081675	0.120	0.054125	0.0894	64383.333333	68400.0	4122.500000	4710.0	NaN	NaN	140.0	
2017-09-04 11:00:00	5.274167	7.98	0.295083	0.657	0.186917	0.276	0.0	0.166	0.063983	0.110	0.033633	0.0684	79933.333333	88200.0	6345.833333	7430.0	NaN	NaN	140.0	
2017-09-04 12:00:00	2.965000	4.85	0.217750	0.428	0.153500	0.239	0.0	0.179	0.071217	0.144	0.037233	0.0679	80516.666667	88700.0	6080.000000	7420.0	NaN	NaN	140.0	
2017-09-04 13:00:00	3.061667	3.86	0.275833	0.551	0.192833	0.329	0.1	0.170	0.083783	0.159	0.041342	0.0611	76733.333333	85900.0	6015.833333	7540.0	NaN	NaN	140.0	
2017-09-04 14:00:00	7.279167	10.80	0.231333	0.409	0.170583	0.313	0.0	0.178	0.070667	0.166	0.037375	0.0888	83025.000000	90200.0	8552.500000	10500.0	NaN	NaN	140.0	
2017-09-22 00:00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
NaN	NaN	381.0	1.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	

Відповідь 4.3:

З **inner** вийшло 600 рядків, а з **outer** - 601. Різниця в останній годині: у таблиці C є запис за 22 вересня о 00:00, а в A та B дані закінчуються 21 вересня. Я обрала **outer**, щоб не втрачати цей запис. Там, де даних немає, залишаються NaN. Значення F10.7 повторюється для кожної години своєї доби, бо це добовий показник.

У підсумку M має 601 рядок і 20 стовпців. Пропуски є в 9 рядках: у 8 годинах 4 вересня після заміни від'ємних значень у C та в останньому записі за 22 вересня, для якого немає потоків частинок і F10.7. **inner** теж залишає ці 8 годин з пропусками, бо він перевіряє збіг часу, а не наявність усіх вимірювань.

Завдання 4.4 - поділ на групи

Щоб далі було що з чим порівнювати, поділіть години на три групи за значенням **максимуму потоку P>10 за годину**:

Група	Умова
тиха	менше 10
активна	від 10 до 1000
дуже активна	1000 і більше

Додайте до `M` стовпець `група` і виведіть, скільки годин потрапило в кожну.

Це не вигадані числа: саме такі пороги використовує метеослужба космічної погоди NOAA. Чому вони саме такі - питання не сьогоднішньої роботи.

```
In [17]: M['група'] = pd.cut(
    M['P>10_max'],
    bins=[-np.inf, 10, 1000, np.inf],
    labels=['тиха', 'активна', 'дуже активна'],
    right=False
)

print('Кількість годин у кожній групі:')
print(M['група'].value_counts(sort=False))

print('Годин без групи:', M['група'].isna().sum())
```

Кількість годин у кожній групі:

```
група
тиха      411
активна   171
дуже активна  18
Name: count, dtype: int64
Годин без групи: 1
```

Самоперевірка етапу 4.

```
In [18]: assert M is not None, 'таблиця M не побудована'
assert 'ts' in M.columns, 'у таблиці M потрібен стовпець ts'
assert 'група' in M.columns, 'у таблиці M потрібен стовпець «група»'
assert 590 <= len(M) <= 605, 'очікується близько 600 рядків, а є %d - перевірте об'єкт'
print('Етап 4 пройдено:', len(M), 'рядків')
```

Етап 4 пройдено: 601 рядків

Етап 5. П'ять графіків - п'ять питань

Графік будується як **відповідь на питання**, а не «щоб був».

Вимоги до кожного графіка:

- підписані обидві осі, з одиницями вимірювання;
- заголовок;
- під графіком, у текстовій клітинці, - **одне речення про дані**. Не «на графіку зображено потік протонів», а твердження на кшталт «більшість годин потік не перевищує 60, але кілька годин дають значення у сотні разів більші».

Не кожне питання має відповідь «так, зв'язок є». Якщо на графіку нічого не видно - так і напишіть. Відсутність зв'язку - це теж результат, і чесно про неї написати важливіше, ніж підбирати ракурс, у якому «щось наче проглядається».

Графік 1. Як розподілені значення вашого потоку?

Побудуйте гістограму вашого потоку (середнє за годину). Порахуйте окремо середнє й медіану цього стовпця.

Якщо гістограма вийде нечитабельною - стовпчик біля нуля і порожньо далі - не залишайте так. Спробуйте побудувати гістограму від логарифма значень (`np.log10`) і подивіться, що зміниться.

Питання: чому середнє й медіана так сильно відрізняються?

```
In [19]: flow = завдання['ваш потік']
values = M[f'{flow}_mean'].dropna()

print('Середнє:', values.mean())
print('Медіана:', values.median())
print('Годин із даними:', len(values))

log_values = np.log10(values[values > 0])

fig, ax = plt.subplots(1, 2, figsize=(13, 4))
fig.suptitle(f'Розподіл погодинного середнього потоку {flow}')

ax[0].hist(values, bins=30, edgecolor='white')
ax[0].set_title('Звичайна гістограма')
ax[0].set_xlabel(f'Потік {flow}, протонів/(см²·с·ср)')
ax[0].set_ylabel('Кількість годин')
ax[0].grid(axis='y', alpha=0.3)


ax[1].hist(log_values, bins=30, edgecolor='white')
ax[1].set_title('Гістограма логарифма значень')
ax[1].set_xlabel(f'log10 потоку {flow} (потік у протонах/(см²·с·ср))')
ax[1].set_ylabel('Кількість годин')
ax[1].grid(axis='y', alpha=0.3)
```

```
fig.tight_layout()
plt.show()
```

Середнє: 18.831272835858584

Медіана: 0.137825

Годин із даними: 600



Висновок: Більшість погодинних значень потоку $P > 30$ низькі, але є й значно вищі, які тягнуть середнє вгору, тому воно більше за медіану.


Графік 2. Чи відрізняється швидкість вітру між групами годин?

Побудуйте діаграму розмаху (`boxplot`) швидкості сонячного вітру окремо для кожної групи з завдання 4.4.

```
In [20]: groups = ['тиха', 'активна', 'дуже активна']

speeds = [M.loc[M['група'] == group, 'speed_km_s'].dropna() for group in groups]

plt.figure(figsize=(8, 4))
plt.boxplot(speeds)
plt.xticks([1, 2, 3], groups)
plt.title('Швидкість сонячного вітру в різних групах годин')
plt.xlabel('Група годин за максимумом потоку  $P > 10$ ')
plt.ylabel('Швидкість сонячного вітру, км/с')
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()
```



Висновок: У дуже активні години більшість швидкостей зосереджена біля 550 км/с, а в тихі й активні години значення розкидані значно ширше, причому медіана в активній групі нижча, ніж у тихій.


Графік 3. Чи пов'язані змінні вашої пари?

Побудуйте діаграму розсіювання для пари з вашого завдання. Порахуйте коефіцієнт кореляції між ними.

```
In [21]: # Для варіанта 6 пара - густина вітру та потік P>1
pair = M[['density_protons_cm3', 'P>1_mean']].dropna()
correlation = pair['density_protons_cm3'].corr(pair['P>1_mean'])
print('Коефіцієнт кореляції Пірсона:', correlation)

plt.figure(figsize=(8, 4))
plt.scatter(pair['density_protons_cm3'], pair['P>1_mean'], alpha=0.5, s=20)
plt.title('Зв'язок густини сонячного вітру та потоку P>1')
plt.xlabel('Густина сонячного вітру, протонів/см³')
plt.ylabel('Середній потік P>1 за годину, протонів/(см²·с·ср)')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

Коефіцієнт кореляції Пірсона: 0.28528892999766575



Висновок: Чіткого зв'язку між густиною вітру та потоком $P > 1$ на графіку не видно: за схожої густини потік може бути як низьким, так і значно вищим.

Графік 4. Скільки годин у кожній групі?

Побудуйте стовпчикову діаграму кількості годин за групами. Підпишіть кожен стовпчик кількістю годин і відсотком від загальної кількості.

```
In [22]: groups = ['тиха', 'активна', 'дуже активна']
counts = M['група'].value_counts().reindex(groups, fill_value=0)
# Враховуємо й години, для яких групу визначити не вдалося
counts.loc['без групи'] = M['група'].isna().sum()

fig, ax = plt.subplots(figsize=(8, 4))
bars = ax.bar(counts.index, counts.values)
for bar, count in zip(bars, counts.values):
    percent = count / len(M) * 100
    ax.text(bar.get_x() + bar.get_width() / 2, count,
            f'{count} год\n{percent:.1f}%', ha='center', va='bottom')

ax.set_title('Кількість годин у кожній групі')
ax.set_xlabel('Група годин за максимумом потоку  $P > 10$ ')
ax.set_ylabel('Кількість годин')
ax.set_ylim(0, counts.max() * 1.2)
ax.set_axisbelow(True)
ax.grid(axis='y', alpha=0.3)
fig.tight_layout()
plt.show()
```



Висновок: Більшість годин були тихими (68.4%), активні становили 28.5%, а дуже активні траплялися рідко - лише 3% часу.

Графік 5. Як усе це виглядало в часі?

Побудуйте лінійний графік максимуму потоку $P > 10$ за годину за весь період спостережень.

Якщо крива виявиться нечитабельною - згадайте, що допомогло в графіку 1.

```
In [23]: # Логарифмічна вісь дозволяє бачити і низькі значення, і сплески
plt.figure(figsize=(11, 4))
plt.plot(M['ts'], M['P>10_max'])
plt.yscale('log')
plt.title('Максимум потоку  $P > 10$  за годину протягом спостережень')
plt.xlabel('Дата, 2017 рік')
plt.ylabel('Максимальний потік  $P > 10$ , протонів/(см2·с·ср)')
plt.xticks(rotation=30)
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```



Висновок: На початку спостережень потік $P > 10$ був низьким, у вересні сталося кілька різких сплесків із найбільшим піком близько 11 вересня, після якого потік поступово повернувся до низьких значень.

Етап 6. Два графіки одних і тих самих даних

Нижче побудовано два графіки. Дані в них **одні й ті самі** - це той самий стовпець з тієї самої таблиці, жодне число не змінено.

Виконайте клітинку й подивіться на обидва.

```
In [24]: СТОВПЕЦЬ = 'P>10_max'    # максимум P>10 за годину


вікно = M[(M['ts'] >= '2017-08-28') & (M['ts'] < '2017-09-05')]

fig, ax = plt.subplots(1, 2, figsize=(12, 3.2))

ax[0].plot(вікно['ts'], вікно[СТОВПЕЦЬ], color='#2a78d6')
ax[0].set_title('Графік 1')
ax[0].tick_params(axis='x', rotation=30)

ax[1].plot(M['ts'], M[СТОВПЕЦЬ], color='#2a78d6')
ax[1].set_yscale('log')
ax[1].set_title('Графік 2')
ax[1].tick_params(axis='x', rotation=30)

fig.tight_layout()
plt.show()
```



Завдання 6.1

Дайте відповідь на три питання:

1. Який висновок про космічну погоду у вересні 2017 року зробить людина, яка бачила **тільки перший** графік?
2. Який висновок зробить людина, яка бачила **тільки другий** графік?

3. Чим ці два графіки відрізняються між собою? Назвіть **дві** відмінності - вони обидві є в кодї вище.

Жодне число в обох графіках не підроблене. Різниця виникла тільки через те, як їх побудували.

Відповідь 6.1:

1. Людина, яка бачила тільки перший графік, подумає: «Космічна погода була спокійною, потік майже не змінювався, і лише наприкінці почалося різке зростання».
2. Людина, яка бачила тільки другий графік, подумає: «У вересні космічна погода була неспокійною: сталося кілька сильних сплесків, найбільший - близько 11 вересня, а потім потік поступово знизився».
3. Перша відмінність - період: перший графік показує тільки 28 серпня - 4 вересня, а другий - увесь період спостережень, тому основні сплески на перший просто не потрапили; друга відмінність - вісь Y: на першому вона звичайна, а на другому логарифмічна, що дозволяє одночасно бачити низькі значення й великі піки.

Завдання 6.2

Уявіть, що вам потрібно **одним графіком** чесно показати, що відбувалося в цьому періоді. Побудуйте його самі й підпишіть заголовком, який формулює висновок.

Поясніть у клітинці нижче, чому ви обрали саме такий вигляд.

```
In [25]: fig, ax = plt.subplots(figsize=(11, 4))
ax.plot(M['ts'], M['P>10_max'])
ax.set_yscale('log')
ax.set_xlim(M['ts'].min(), M['ts'].max())

ax.set_title('Після сильних сплесків у вересні потік P>10 повернувся до низьких зна
ax.set_xlabel('Дата, 2017 рік')
ax.set_ylabel('Максимум P>10 за годину, протонів/(см²·с·ср)\n(логарифмічна шкала)')
ax.tick_params(axis='x', rotation=30)
ax.grid(alpha=0.3)
fig.tight_layout()
plt.show()
```



Відповідь 6.2:

Я взяла весь період спостережень, щоб було видно і спокійний початок, і сплески у вересні, і зниження потоку після них. Обрала лінійний графік, бо він показує, як потік змінювався з часом. Вісь Y зробила логарифмічною: значення відрізняються в тисячі разів, тому на звичайній шкалі низькі значення зливаються біля нуля. Тип шкали вказала в підписі осі, щоб було зрозуміло, що однакові відстані по вертикалі означають зміну в однакову кількість разів.

Етап 7. Три спостереження та ваше питання

Завдання 7.1

Запишіть **три спостереження** про ці дані, які ви зробили під час роботи.

Спостереження - це твердження, яке спирається на конкретне число або графік з вашого ноутбука. Не «дані цікаві», а, наприклад, «максимальне значення потоку у 2000 разів більше за медіанне, і всі такі години припадають на одні й ті самі три доби».

Для кожного вкажіть, **де саме** у вашій роботі його видно.

Спостереження 1: Середнє значення $P > 30$ вийшло близько 18.83, а медіана - лише 0.138, тобто за одним середнім можна подумати, що потік зазвичай набагато вищий, ніж є насправді. На гістограмах видно, що більшість значень низькі, а середнє піднімають великі сплески. Це видно в етапі 5, на графіку 1 та в обчисленнях перед ним.

Спостереження 2: Дуже активні години не означають, що вітер тоді був найшвидшим: у цій групі швидкості переважно близькі до 550 км/с, а в тихій та активній трапляються значення близько 800 км/с. Тобто активність за потоком протонів і швидкість вітру - не одне й те саме. Це видно на графіку 2 етапу 5.

Спостереження 3: Тихих годин було найбільше - 68.4%, але це не означає, що весь період був спокійним: близько 11 вересня максимум $P > 10$ за годину перевищував 1000 протонів/(см²·с·ср). Виходить, сильні сплески займали невелику частину часу, але дуже виділялися на тлі решти спостережень. Це видно на графіках 4 і 5 етапу 5.

Завдання 7.2 - ваше індивідуальне питання

Дайте відповідь на додаткове питання зі свого завдання. Відповідь має спиратися на обчислення: наведіть код і результат, а потім сформулюйте висновок словами.

```
In [26]: # Моє питання: у яку добу середній потік був найбільшим і найменшим?
flow = завдання['ваш потік']

# Рахуємо добове середнє з погодинних середніх
daily_mean = M.set_index('ts')[f'{flow}_mean'].resample('D').mean().dropna()
max_day = daily_mean.idxmax()
min_day = daily_mean.idxmin()

print(f'Добові середні потоку {flow}, протонів/(см²·с·ср):')
print(daily_mean)
print(f'Найбільше: {max_day:%d.%m.%Y} - {daily_mean.loc[max_day]:.4f}')
print(f'Найменше: {min_day:%d.%m.%Y} - {daily_mean.loc[min_day]:.4f}')
```

Добові середні потоку $P > 30$, протонів/(см²·с·ср):

```
ts
2017-08-28    0.092297
2017-08-29    0.091266
2017-08-30    0.094493
2017-08-31    0.092415
2017-09-01    0.089734
2017-09-02    0.090684
2017-09-03    0.098962
2017-09-04    0.106562
2017-09-05    0.650576
2017-09-06    1.555274
2017-09-07    4.723908
2017-09-08    2.247031
2017-09-09    0.168946
2017-09-10    82.230478
2017-09-11   292.930556
2017-09-12    64.703125
2017-09-13    13.776701
2017-09-14     5.486859
2017-09-15     0.660118
2017-09-16     0.278938
2017-09-17     0.140767
2017-09-18     0.136539
2017-09-19     0.121408
2017-09-20     0.109478
2017-09-21     0.104707
Freq: D, Name: P>30_mean, dtype: float64
Найбільше: 11.09.2017 - 292.9306
Найменше: 01.09.2017 - 0.0897
```

Відповідь 7.2: Найбільше добове середнє мого потоку $P > 30$ було 11 вересня - приблизно 292.93 протона/(см²·с·ср), а найменше 1 вересня - приблизно 0.0897 протона/(см²·с·ср). Отже, найвищий середній потік припав на період сильного сплеску, а найнижчий - на спокійний початок вересня. Я рахувала середнє за добу з погодинних середніх; 22 вересня не враховувала, бо для цієї дати в М немає значень $P > 30$.

Етап 8. Декларація про використання інструментів штучного інтелекту

Користуватися мовними моделями під час виконання цієї роботи **дозволено**. Це нормальна інженерна практика, і курс про штучний інтелект не має підстав її забороняти.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом - так само, як у науковій статті вказують використане програмне забезпечення.

Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок вашого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Якщо код згенеровано, але ви його розумієте - робота зарахована. Якщо не розумієте - не зарахована, незалежно від того, хто його написав.

Завдання 8.1

Заповніть словник. Для кожного етапу оберіть одне з формулювань:

- 'ні' - інструментами ШІ не користувався;
- 'синтаксис' - питав про назву функції або синтаксис, код писав сам;
- 'код, перевірено' - код згенеровано, я його прочитав, перевінив і розумію;
- 'текст, перероблено' - згенеровано чернетку тексту, яку я переписав по суті;
- 'текст, як є' - згенерований текст залишено майже без змін.

Останній варіант не заборонений, але прямо впливає на оцінку: бали ставляться за висновки, а не за наявність абзацу.

```
In [27]: ІНСТРУМЕНТИ_ШІ = 'Codex'      # напр. 'ChatGPT' або 'не використовував'
```

```
ДЕКЛАРАЦІЯ = {
    'етапи 1-2, читання файлу та розбір таблиць': 'код, перевірено',
    'етап 3, паспорт даних і дивні значення':      'код, перевірено',
    'етап 4, об'єднання таблиць':                  'код, перевірено',
    'етап 5, побудова графіків':                    'код, перевірено',
    'етап 5, формулювання висновків':               'текст, перероблено',
```

```

    'етапи 6-7, порівняння графіків і спостереження': 'код, перевірено',
}

# Що саме ви перевірили за згенерованим кодом чи текстом - конкретно:
# які числа звірили, що переписали, де знайшли помилку.
ЩО_ПЕРЕВІРЕНО = 'помилка не було, всі числа я звірила. Все згенеровано було коректн

# True означає: я можу пояснити кожен рядок свого коду, відтворити будь-який
# результат цієї роботи та внести зміни в код на вимогу під час захисту.
ПІДТВЕРДЖУЮ = True

```

```

In [28]: # --- перевірка повноти декларації: клітинку не редагувати -----
ДОЗВОЛЕНІ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено', 'текст, як

assert ІНСТРУМЕНТИ_ШІ.strip(), 'Вкажіть інструменти або напишіть «не використовував
порожні = [k for k, v in ДЕКЛАРАЦІЯ.items() if not str(v).strip()]
assert not порожні, 'Не заповнено пункти декларації: %s' % '; '.join(порожні)
чужі = {v for v in ДЕКЛАРАЦІЯ.values() if v not in ДОЗВОЛЕНІ}
assert not чужі, 'Недопустимі значення: %s. Оберіть з переліку вище.' % ', '.join(s
assert len(ЩО_ПЕРЕВІРЕНО.strip()) >= 120, ('Опишіть конкретніше, що саме ви переві
          '(зараз %d символів, потрібно щонайменше
          % len(ЩО_ПЕРЕВІРЕНО.strip()))
assert ПІДТВЕРДЖУЮ is True, 'Підтвердьте, що можете пояснити власний код на захисті

print('ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ')
print('=' * 78)
print('%-46s %s' % ('автор:', ПІБ))
print('%-46s %s' % ('інструменти:', ІНСТРУМЕНТИ_ШІ))
print('-' * 78)
for k, v in ДЕКЛАРАЦІЯ.items():
    print('%-46s %s' % (k + ':', v))
print('-' * 78)
print('перевірено автором:')
print(ЩО_ПЕРЕВІРЕНО)
print('=' * 78)
print('Автор підтверджує, що може пояснити кожен рядок коду під час захисту.')

```

ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ

```
=====
```

автор:	Козак Наталія
інструменти:	Codex

```
-----
```

етапи 1-2, читання файлу та розбір таблиць:	код, перевірено
етап 3, паспорт даних і дивні значення:	код, перевірено
етап 4, об'єднання таблиць:	код, перевірено
етап 5, побудова графіків:	код, перевірено
етап 5, формулювання висновків:	текст, перероблено
етапи 6-7, порівняння графіків і спостереження:	код, перевірено

```
-----
```

перевірено автором:

помилка не було, всі числа я звірила. Все згенеровано було коректно, оскільки я чітко вказувала що і як робити. Висновки переписала, щоб було коротко і по суті.

```
=====
```

Автор підтверджує, що може пояснити кожен рядок коду під час захисту.

Крок 9. Збереження результату та фінальна самоперевірка

Об'єднана таблиця знадобиться вам у лабораторних роботах № 3 і № 4 - збережіть її й не втрачайте до кінця семестру.

```
In [29]: M.to_csv('master_hourly.csv', index=False)
print('збережено:', M.shape)
```

збережено: (601, 21)

```
In [30]: # --- фінальна самоперевірка -----
перевірки = {
    'ПІБ і варіант заповнено': bool(ПІБ) and bool(ВАРІАНТ),
    'таблиця А (7200 рядків)': len(A) == 7200,
    'таблиця В (25 рядків)': len(B) == 25,
    'таблиця С (601 рядок)': len(C) == 601,
    'таблиці об'єднано': M is not None and 590 <= len(M) <= 605,
    'стовпець «група» є': 'група' in M.columns,
    'усі дати у 2017 році': int(pd.to_datetime(M['ts']).dt.year.min()) ==
    'декларацію заповнено': bool(ІНСТРУМЕНТИ_ШІ.strip()) and ПІДТВЕРДЖУЮ
}
for k, v in перевірки.items():
    print(('OK' if v else 'НЕ OK') + ' ' + k)

if all(перевірки.values()):
    print('\nТехнічна частина роботи виконана.')
    print('Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та висновка')
    print('і виконайте Kernel → Restart & Run All перед здачею.')
```

```
OK    ПІБ і варіант заповнено
OK    таблиця А (7200 рядків)
OK    таблиця В (25 рядків)
OK    таблиця С (601 рядок)
OK    таблиці об'єднано
OK    стовпець «група» є
OK    усі дати у 2017 році
OK    декларацію заповнено
```

Технічна частина роботи виконана.

Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та висновками,
і виконайте Kernel → Restart & Run All перед здачею.